

Comment comprendre ce que mesure l’Insee ?

Terminologie, déplacements sémantiques et thématiques dans les publications Insee
Première et Insee Analyse entre 2010 et 2025

Paul Dupire, Catherine Berleur

 Github Projet PESSD

 Notebook à télécharger Projet PESSD

paul.dupire@ensae.fr ; catherine.berleur@ensae.fr

Résumé

Nous nous intéressons à l’évolution des publications *Insee Première* et *Insee Analyse* entre 2010 et 2025 à travers une approche en traitement automatique du langage. En utilisant des plongements lexicaux diachroniques basés sur Word2Vec et la méthode Skip-gram, nous cartographions la structure terminologique des publications de l’Insee et suivons ses transformations dans le temps. Notre méthodologie révèle une organisation cohérente du vocabulaire en groupes thématiques stables, tout en identifiant des évolutions significatives comme le développement d’analyses territoriales localisées. L’étude de cas du terme « décile » illustre une généralisation transversale de l’approche distributionnelle dans le corpus plutôt qu’un déplacement méthodologique. Ces résultats contribuent à la sociologie de la quantification en proposant une méthode capable de suivre les évolutions structurelles et les trajectoires des méthodes statistiques au sein des publications de la statistique publique.

Mots clés : Plongement lexical diachronique, Word2vec, NLP, Skip-gram, Insee

1 Introduction et Problématique

Notre étude analyse les publications de l’Insee entre 2010 et 2025 afin d’en comprendre les évolutions. En nous intéressant au contenu de ces publications, c’est-à-dire les connaissances scientifiques produites, les théories et méthodes mobilisées, ainsi que les thématiques explorées, nous cherchons à caractériser les transformations récentes de la statistique publique telle qu’elle est produite par l’Insee. Plus précisément, il s’agit de saisir l’articulation entre les méthodes et indicateurs statistiques d’une part, et l’espace des thématiques abordées d’autre part.

Cette démarche s’inscrit dans le champ de la sociologie de la quantification, et plus particulièrement dans celui de la sociologie de la statistique publique. L’usage d’une terminologie particulière pour décrire ou classer des phénomènes n’est jamais neutre : il encadre la manière dont les résultats sont perçus et interprétés. La sociologie des sciences et de la quantification a montré que les outils conceptuels et méthodologiques façonnent non seulement les résultats, mais aussi la manière dont ils sont produits et diffusés.(1; 4)

Un exemple emblématique analysé par Alain Desrosières et Laurent Thévenot (2) est celui du « revenu » utilisé comme « variable explicative », qui tend à s’imposer à la fin des années 1970. Ce choix assimile l’espace social à une « échelle ordonnée et continue », impliquant des relations causales linéaires entre revenu et position sociale. La fréquence du terme « revenu » dans les publications de l’Insee renseigne sur les priorités thématiques de l’institution. Son association avec d’autres termes tels que « linéaire », « régression » ou « analyse en composantes principales » éclaire le cadre statistique dans lequel il s’inscrit. Une approche diachronique permet d’interroger les interactions entre ces cadres. Nous identifions trois aspects dans notre problématique principale :

- **Dresser un panorama de la terminologie employée par l’Insee.** Nous cherchons à cartographier la structure des publications de l’Insee en identifiant les thématiques abordées, leurs interactions, ainsi que les terminologies associées. L’objectif est également de repérer l’apparition ou la disparition de certains termes, les substitutions lexicales, et les associations lexicales récurrentes.
- **Comprendre l’évolution temporelle des thématiques de l’Insee.** Il s’agit d’analyser les mutations thématiques, en observant tant l’émergence de nouveaux sujets que la variation de leur importance relative dans la production statistique de l’Institut.
- **Saisir l’articulation entre les méthodes et les indicateurs statistiques et l’espace des thématiques abordées.** Nous nous intéressons à l’évolution des approches méthodologiques dans leur rapport aux thématiques traitées, afin de mettre en évidence les transformations conjointes du langage statistique et des objets étudiés.

Ce travail repose sur l’hypothèse que le langage reflète certaines subtilités du travail de quantification : les conventions autour des variables, les choix terminologiques, et les mesures qui leur sont associées. L’usage d’une terminologie spécifique circonscrit non seulement la compréhension de l’objet d’étude, mais aussi l’information produite et sa mise en forme.

En détournant la formule de l’Insee, « mesurer pour comprendre », notre objectif peut se reformuler ainsi : **comment comprendre ce que mesure l’Insee ?**

2 Présentation des données

Le corpus sur lequel repose notre analyse textuelle provient de deux collections publiques de l’Insee, couvrant un large éventail de thématiques :

- **Insee Première** : publications courtes (quatre pages) en lien avec l’actualité, présentant des résultats significatifs sur un sujet précis (790 publications entre 2011 et 2025).
- **Insee Analyse** : documents de travail ou articles synthétiques (également quatre pages), mettant davantage l’accent sur l’aspect méthodologique (100 publications entre 2010 et 2025).

Nous avons choisi ces collections parce qu’elles reflètent le travail de l’Insee sur les sujets qu’ils considèrent comme d’actualité, en lien avec des enjeux économiques, sociaux ou politiques (?). Elles témoignent également des analyses approfondies menées par les statisticiens publics et offrent un large aperçu des productions de l’institut dans un format standardisé. À partir de ce corpus, nous avons extrait les variables essentielles à notre analyse :

- Dates de publication, texte complet des articles, thème (exemple : Comptabilité nationale) et sous-thème (exemple : Comptes nationaux annuels), titre et sous-titre, onglets méthodologiques, concepts utilisés.

Afin de mieux saisir l'évolution temporelle des productions, nous avons segmenté notre corpus en quatre périodes de quatre ans, couvrant l'intervalle 2010–2025. Ce découpage permet une analyse diachronique fine, tout en garantissant un volume suffisant d'articles pour appliquer efficacement les méthodes de traitement automatique du langage (NLP).

3 Stratégie empirique

Notre stratégie empirique est articulée autour de quatre étapes permettant à la fois de comprendre la structure des publications, l'évolution de la terminologie et l'articulation des méthodes et des thématiques au cours du temps : préparation du corpus en vue d'un traitement automatique du langage, représentation vectorielle du corpus et de sa terminologie, alignement diachronique des espaces vectoriels, et visualisation et interprétation.

3.1 Découpage temporel et préparation du corpus

Le corpus est constitué d'un ensemble d'articles produits par l'Insee. Après une phase d'extraction des textes bruts, nous procédons à une normalisation linguistique : lemmatisation (exemple : « petites, petite » deviennent « petit »), suppression des mots-outils et ponctuations, conversion en minuscules, et traitement des entités nommées fréquentes mais annexes (par exemple : “insee”, “tableau”) pour éviter leur sur-représentation.

Le corpus est ensuite segmenté en quatre tranches temporelles égales (2010–2013, 2014–2017, 2018–2021, 2022–2025). Ce choix vise à équilibrer l'analyse diachronique. Chaque sous-corpus est traité séparément pour entraîner des modèles de représentation spécifiques à chaque période. Le corpus complet fait également l'objet d'un traitement

Les métadonnées associées aux documents (thème principal, sous-thèmes, mots similaires) sont extraites parallèlement aux textes. Elles servent ensuite à relier les évolutions lexicales aux axes institutionnels du discours statistique.

3.2 Représentation vectorielle des mots

Afin de modéliser la structure sémantique du corpus, nous avons recours à *Word2Vec* dans sa configuration *Skip-Gram*, une méthode d'apprentissage non supervisée qui repose sur l'idée que le sens d'un mot peut être approché par les mots qui l'entourent. Pour le dire autrement : “*you shall know a word by the company it keeps*” (3).

Formellement, soit $(w_1, w_2, \dots, w_T)$ une séquence de mots observée dans le corpus, où T désigne la longueur totale du corpus. Pour chaque position $t \in [1, T]$, le modèle considère une fenêtre de contexte symétrique de taille c (ici $c = 10$) autour du mot cible w_t (exemple : « décile »).

Le modèle *Skip-Gram* a pour objectif de maximiser la probabilité conjointe des mots de contexte w_{t+j} conditionnellement au mot cible w_t , pour tout j tel que $-c \leq j \leq c$ et $j \neq 0$. L'objectif d'apprentissage global s'écrit donc :

$$\mathcal{L} = \sum_{t=1}^T \sum_{\substack{-c \leq j \leq c \\ j \neq 0}} \log P(w_{t+j} | w_t)$$

où $P(w_{t+j} | w_t)$ représente la probabilité d'observer un mot de contexte w_{t+j} sachant le mot central w_t . Cette probabilité est modélisée via une fonction *softmax* :

$$P(w_O | w_I) = \frac{\exp(v_{w_O}^\top \cdot u_{w_I})}{\sum_{w \in \mathcal{V}} \exp(v_w^\top \cdot u_{w_I})}$$

où u_{w_I} est le vecteur du mot d'entrée (cible), v_{w_O} celui du mot de sortie (contexte), et $\mathcal{V}$ le vocabulaire.

Le résultat de cet apprentissage est un espace vectoriel de dimension $d = 200$, dans lequel chaque mot w est représenté par un vecteur $v_w \in \mathbb{R}^d$ capturant ses régularités d'usage dans le corpus.

À titre d'exemple, si le mot cible est « décile », et que la phrase analysée est « les ménages du premier décile de revenu », alors les mots du contexte tels que « ménages », « revenu » ou « premier » seront utilisés comme sorties à prédire. Le vecteur associé au mot « décile » sera construit de manière à maximiser la probabilité de co-occurrence avec ces mots contextuels, renforçant ainsi son ancrage sémantique dans le champ de la distribution des revenus. Les similarités sémantiques sont ensuite évaluées par la similarité cosinus, ce qui est la mesure principale pour évaluer la proximité entre les vecteurs :

$$\text{sim}(w_i, w_j) = \frac{v_{w_i} \cdot v_{w_j}}{\|v_{w_i}\| \|v_{w_j}\|}$$

L'entraînement est effectué indépendamment pour chaque période temporelle, sur un sous-corpus préalablement lemmatisé et nettoyé, en imposant un seuil minimal de 2 occurrences par mot.

En complément des vecteurs, chaque mot est également associé à une distribution thématique empirique, construite à partir des métadonnées précédemment citées. Pour un mot w , on définit une mesure de fréquence relative par thème, qui sert à déterminer les fréquences d'utilisation de ce mot dans chaque thème.

Cette double représentation, vectorielle et fréquentielle, constitue le socle de l'analyse diachronique, permettant de relier les glissements sémantiques et les réorientations thématiques.

3.3 Alignement diachronique des espaces vectoriels

Les modèles *Word2Vec* étant entraînés indépendamment sur chaque sous-corpus, leurs espaces vectoriels ne sont pas directement comparables. Pour analyser les évolutions dans le temps, nous mettons en œuvre une procédure d'alignement par transformation de *procrustes* orthogonale. Cette méthode consiste à apprendre une matrice de rotation entre deux espaces vectoriels successifs (par exemple, entre 2010–2013 et 2014–2017), de manière à minimiser la distance euclidienne entre les vecteurs du vocabulaire commun aux deux corpus (en fonction de leur importance dans le corpus). L'alignement est appliqué récursivement de période en période, créant ainsi un espace unifié dans lequel chaque vecteur peut être projeté (5).

Une fois les espaces alignés, nous suivons les trajectoires individuelles des termes d'une période à l'autre. Ces trajectoires sont analysées selon deux indicateurs principaux : (1) la distance vectorielle cumulée, qui permet de mesurer la stabilité ou le déplacement sémantique d'un terme ; (2) le changement de voisinage sémantique, défini par les k plus proches voisins du terme dans chaque période.

Dans un souci de lisibilité et de concision, nous choisissons pour cette étude une seule trajectoire qui permet de mettre en lumière les avantages et les écueils de cette méthode.

3.4 Visualisation et interprétation

Pour rendre compte de l'organisation globale des termes dans l'espace vectoriel et de leurs évolutions, nous appliquons une réduction de dimension à l'aide de l'algorithme PaCMAP (Pairwise Controlled Manifold Approximation). Si l'ACP (Analyse en Composantes Principales) est une méthode classique pour ce type de tâche, elle repose sur une hypothèse de linéarité et de composantes principales non corrélées qui limite sa capacité à capturer les structures non linéaires typiques des espaces sémantiques Word2Vec, liées à la polysémie des termes.

PaCMAP fonctionne en équilibrant les plus proches voisins de chaque point à différents niveaux : les voisins proches, les voisins moyennement éloignée et les voisins éloignées. Cette approche permet de conserver la structure locale des liens entre les vecteurs et la structure globale de l'espace vectoriel, ce qui rend PaCMAP particulièrement adapté à la visualisation d'espaces Word2Vec.(6)

Cette réduction de dimensionnalité nous permet de visualiser l'espace de la terminologie employée.

4 Statistiques descriptives

L'Insee produit une catégorisation de ses articles inchangée depuis au moins quinze ans comportant neuf thèmes et quarante-trois sous-thèmes. Notre première analyse de la structure des publications et de la stabilité de celle-ci repose sur des statistiques descriptives.

Les volumes des publications des séries Insee Première et Insee Analyse ont globalement augmenté au cours de la période étudiée. Le nombre moyen de publications annuelles est passé de 66,8 entre 2010 et 2013 à 81,0 entre 2022 et 2024. Cette croissance progressive, mais non linéaire, permet l'intégration

de nouveaux sujets ou l’approfondissement de thématiques existantes, sans pour autant remplacer les précédentes. Un exemple particulièrement illustratif de cette évolution concerne les comptes nationaux, dont la couverture dans Insee Première a été renforcée à la suite de réorganisations internes à l’institut, passant de 2 publications annuelles en 2010-2013 à 10 en 2022-2024.




FIGURE 1 – Distribution des thèmes par périodes de 4 ans en %

La stabilité structurelle des publications se manifeste par une répartition thématique globalement constante malgré les évolutions conjoncturelles. Les thèmes dominants, en proportion, restent invariablement le marché du travail et les salaires (17,9% des publications sur l’ensemble de la période), les analyses centrées sur les entreprises (16,3%) et les études sectorielles détaillées (16,1%). La persistance de cette structure permet d’envisager des comparaisons temporelles pertinentes pour comprendre les évolutions méthodologiques.

Cette stabilité se retrouve également dans la hiérarchisation interne des sous-thèmes de l’Insee. Toutefois, cette constance ne signifie pas une rigidité des calendriers de publication, à l’exception notable des comptes nationaux, qui suivent une périodicité réglementaire stricte. Insee Première et Insee Analyse maintiennent ainsi une flexibilité éditoriale tout en préservant un cadre thématique cohérent.

Le maintien d’un nombre relativement constant de publications par période quadriennale (266 pour 2010-2013, 242 pour 2014-2017, 287 pour 2018-2021 et 243 pour 2022-2024, sans inclure l’année 2025 incomplète) constitue un avantage méthodologique majeur pour notre analyse. Cette homogénéité volumétrique, combinée à la stabilité des catégories thématiques, crée des conditions favorables à des comparaisons entre les espaces vectoriels que nous construisons. En effet, cette constance structurelle minimise les biais potentiels liés à des déséquilibres quantitatifs entre les périodes, renforçant ainsi la robustesse des techniques de plongement lexical diachronique que nous appliquons.

5 Résultats

5.1 Une structure cohérente et informative de la terminologie employée

L’analyse du plongement lexical des publications Insee Première et Insee Analyse entre 2010 et 2025 met en évidence une structuration cohérente et lisible du vocabulaire utilisé par l’Insee. La projection de ces représentations vectorielles dans l’espace, ici réalisée via la réduction PaCMAP (Figure 2), révèle une organisation spatiale cohérente, dans laquelle les termes se regroupent selon des affinités sémantiques.

Cette cartographie lexicale permet d’identifier des ensembles bien définis correspondant aux grands domaines d’analyse de l’Insee. On distingue ainsi des clusters clairs autour de l’agriculture, de l’emploi, des entreprises, de la démographie, du logement ou encore des dynamiques territoriales.




FIGURE 2 – PaCMAP du plongement lexical d'Insee Première et Insee Analyse sur la période 2010-2025

Note : Chaque point correspond à un mot. Les clusters sont obtenus par la méthode d'*Agglomerative Clustering*. Les zones colorées sont ajoutées par l'auteur pour plus de lisibilité.

La disposition de ces groupes n'est pas une projection fidèle des thèmes institutionnels : elle révèle que les thématiques de l'Insee se différencient et s'organisent avant tout comme des espaces lexicaux. En d'autres termes, si certaines thématiques apparaissent proches dans la carte, c'est précisément parce qu'elles mobilisent des vocabulaires similaires. À l'inverse, des champs éloignés le sont parce qu'ils reposent sur des emplois terminologiques distincts. L'espace vectoriel ne reproduit donc pas un découpage préexistant : il rend visible une structuration émergente du corpus fondée sur les régularités d'usage des mots. Celle-ci est de fait alignée avec les thèmes établis par l'Insee.

Cet espace rend visibles les proximités sémantiques non seulement à l'intérieur des thématiques, où les termes fortement liés coexistent dans des régions denses, mais également entre elles. Certaines zones d'interface mettent en lumière des continuités lexicales entre champs habituellement distingués : par exemple, des termes liés à l'emploi apparaissent parfois à la frontière des clusters sur la démographie ou sur la formation, révélant des contextes partagés d'analyse. Ces zones de transition traduisent une articulation fine entre catégories, difficilement perceptible dans une lecture strictement thématique des publications.

La représentation présente un double intérêt méthodologique. Elle démontre d'abord la capacité des plongements lexicaux à restituer les structures sémantiques latentes d'un corpus spécialisé, en révélant l'organisation implicite du vocabulaire mobilisé. Elle constitue ensuite un outil d'exploration original de la production de l'Insee, permettant d'étudier simultanément la stabilité des grands blocs thématiques et les dynamiques internes de recomposition.

5.2 Un développement d'analyses locales sans substitution

La visualisation sur plusieurs périodes des plongements lexicaux met en évidence une évolution significative dans l'approche territoriale des publications de l'Insee. La Figure 3 illustre comment le lexique lié aux villes et aux régions s'est progressivement enrichi et autonomisé au cours de la période étudiée.




FIGURE 3 – Evolution temporelle du lexique lié aux villes et régions et du lexique lié à la production agricole

Les noms de villes, d'agglomérations ou de régions, initialement intégrés dans des clusters thématiques liés à la démographie ou aux entreprises, tendent à former progressivement un ensemble distinct et de plus en plus dense. Cette migration lexicale témoigne d'un développement croissant des analyses locales dans les publications de l'Insee. Il est important de noter que cette évolution ne s'opère pas par substitution : contrairement à une hypothèse de remplacement thématique, nous constatons plutôt un enrichissement du corpus avec l'ajout de nouvelles dimensions d'analyse territoriale.

Cette tendance contraste avec la stabilité observée dans d'autres domaines comme l'agriculture. En effet, le lexique agricole conserve une position et une structure relativement constantes dans notre espace vectoriel au fil des périodes étudiées. Ses voisins sémantiques restent similaires, et l'importance relative de cette thématique ne diminue pas.

La comparaison entre l'évolution du lexique territorial et la stabilité du lexique agricole illustre comment notre méthodologie permet de visualiser et d'évaluer les transformations thématiques dans les publications de l'Insee. Elle révèle une stratégie d'enrichissement thématique plutôt que de substitution, où les nouvelles dimensions analytiques viennent compléter le cadre existant sans le remplacer.

5.3 Etude de cas : L'approche distributionnelle se déplace-t-elle vraiment ?

L'analyse de la trajectoire du terme « décile » dans l'espace vectoriel (Figure 4) offre un cas d'étude des transformations méthodologiques dans les publications de l'Insee que nous permettent de déceler notre méthode, mais également ses limites. Au premier abord, les déplacements importants de ce terme statistique au sein de l'espace obtenu par plongement lexical diachronique pourraient suggérer un changement radical dans son utilisation ou dans l'approche distributionnelle à laquelle il est associé.

Cependant, une analyse plus approfondie révèle une réalité plus nuancée. La Figure 5, qui présente l'occurrence du terme « décile » dans les différents thèmes au cours du temps, montre que ces déplacements vectoriels ne correspondent pas à un abandon de l'usage du terme dans certains domaines au profit d'autres, mais plutôt à une généralisation de son emploi à travers l'ensemble des thématiques traitées par l'Insee.

En effet, si « décile » était initialement associé principalement aux analyses de revenus et de pouvoir d'achat, nous observons une inflation progressive de son utilisation dans d'autres thèmes comme le marché du travail, les conditions de vie, la démographie ou encore les études sectorielles. Cette diffusion transversale explique les modifications de voisinage sémantique observées dans l'espace vectoriel : ce n'est pas tant le concept qui se déplace d'un domaine à un autre, mais plutôt son application qui s'étend à de multiples champs d'analyse.




FIGURE 4 – Trajectoire du terme « décile » dans l'espace vectoriel obtenu par plongement lexical diachronique entre 2010 et 2025.

Des résultats similaires peuvent être observés avec d'autres termes statistiques comme « quartile » ou « distribution », confirmant cette tendance à la généralisation des approches distributionnelles dans

l'ensemble du corpus. Ce phénomène témoigne d'une évolution méthodologique significative : l'approche par distribution, initialement circonscrite à certains domaines spécifiques, devient progressivement un outil analytique transversal mobilisé dans des contextes de plus en plus diversifiés.




FIGURE 5 – Occurrence du terme « décile » dans les différents thèmes au cours du temps

Cette étude de cas illustre comment les déplacements sémantiques observés dans notre espace vectoriel peuvent révéler des transformations dans les pratiques méthodologiques de l'Insee. Elle souligne également l'importance d'une analyse croisée entre la position des termes dans l'espace vectoriel et leur distribution thématique empirique pour éviter les interprétations erronées des évolutions terminologiques. Les déplacements vectoriels peuvent signaler aussi bien des changements de signification que des modifications dans les contextes d'utilisation d'un terme. Dans le cas de « décile », ce n'est pas tant le concept qui évolue, mais plutôt son champ d'application qui s'élargit.

6 Conclusion : Mesurer ce que comprend l'Insee

Notre étude sur les publications Insee Première et Insee Analyse entre 2010 et 2025 a permis de mettre en lumière les évolutions terminologiques et thématiques de la statistique publique. En mobilisant des techniques de plongement lexical diachronique, nous avons pu cartographier l'espace conceptuel des publications de l'Insee et en suivre les transformations au fil du temps.

Nos résultats révèlent une structure lexicale cohérente et stable qui reflète les principales thématiques de l'institut, tout en mettant en évidence des évolutions significatives, notamment le développement progressif d'analyses territoriales localisées qui viennent enrichir le corpus sans se substituer aux thématiques existantes. L'étude de cas sur le terme « décile » illustre quant à elle les possibilités et les limites de notre approche méthodologique, en montrant comment un déplacement dans l'espace vectoriel peut signaler une diffusion transversale d'une approche statistique plutôt qu'un changement conceptuel.

Cette recherche contribue ainsi à la sociologie de la quantification en offrant une méthode, insuffisante mais pertinente, pour analyser les transformations des cadres conceptuels et méthodologiques de la statistique publique. Elle permet de répondre, au moins partiellement, à notre question initiale : « Comment comprendre ce que mesure l'Insee ? » en montrant comment le langage méthodologique évolue et se structure autour de thématiques et d'approches statistiques qui reflètent les évolutions et les pratiques de la statistique publique.

Références

- [1] Alain Desrosières et al., Li / représentation statistique et représentation politique des groupes professionnels, in *Les catégories socioprofessionnelles*, pp. 30–49, La Découverte, 2002, available from : <https://shs.cairn.info/les-cATEGORIES-socioprofessionnelles--9782707138569-page-30?lang=fr>.
- [2] Alain Desrosières, Laurent Thévenot, L’approche statistique des catégories socioprofessionnelles : L’exemple des nomenclatures d’activité et de profession, *Économie et Statistique*, **110**(1) :49–65, 1979, available from : https://www.persee.fr/doc/estat_0336-1454_1979_num_110_1_4260.
- [3] Firth, J. R., *Studies in Linguistic Analysis*, Philosophical Library, Oxford, 1957. Issued by the Philological Society
- [4] Alice Henneguelle, Arthur Jatteau, *Sociologie de la quantification*, La Découverte, 2021, <https://doi.org/10.3917/dec.henne.2021.01>, available from : <https://doi-org.ezproxy.universite-paris-saclay.fr/10.3917/dec.henne.2021.01>.
- [5] Syrielle Montariol, Matej Martinc, Lidia Pivovarova, Scalable and interpretable semantic change detection, in Kristina Toutanova, Anna Rumshisky, Luke Zettlemoyer, Dilek Hakkani-Tur, Iz Beltagy, Steven Bethard, Ryan Cotterell, Tanmoy Chakraborty, Yichao Zhou (Eds.), *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, Association for Computational Linguistics, Online, June 2021, pp. 4642–4652, <https://doi.org/10.18653/v1/2021.naacl-main.369>, available from : <https://aclanthology.org/2021.naacl-main.369/>.
- [6] Yingfan Wang, Haiyang Huang, Cynthia Rudin, Yaron Shaposhnik, Understanding how dimension reduction tools work : An empirical approach to deciphering t-sne, umap, trimap, and pacmap for data visualization, *arXiv preprint arXiv :2012.04456*, 2020, available from : <https://arxiv.org/abs/2012.04456>.